

Devis 202507-1

Plan de recherche et tarification

Conception et développement d'un algorithme d'évaluation
de la prononciation du Français L2

Émis le 30 juillet 2025

Valide jusqu'au 30 août 2025

Proposé par :

Malo Olivier EI

Entrepreneur Individuel

SIREN : 897870069

Code APE : 6201Z

100 Rue de la Porte de TRIVAUX

92140 CLAMART

Tél : 06 01 45 61 19

Email : MaloOlivier333@gmail.com

Pour :

Fonetix

Association

SIREN : 844096883

5 Impasse NEGRENEYS

31200 TOULOUSE

Représentée par : Laure Fesquet / Sébastien Palusci

30 juillet 2025

Table des matières

1	Introduction	2
1.1	Contexte du projet	2
1.2	Objectifs	2
2	Méthodologie de recherche	3
2.1	Objectif premier : conception d'une <i>baseline</i> de phonémisation, de segmentation syllabique et d'un score de compréhensibilité	3
2.2	Deuxième objectif : proposer un modèle d'analyse prosodique	3
2.3	Dernier objectif : approfondir le modèle prosodique et aborder une intégration holistique	5
3	Livrables attendus	6
4	Planning et <i>milestones</i>	6
5	Proposition tarifaire	7

1 Introduction

Ce document présente le plan de recherche et la proposition tarifaire pour le développement d'un algorithme d'évaluation de la prononciation du Français L2.

Ce plan de recherche vise à développer un algorithme d'évaluation automatique de la prononciation du Français L2, répondant aux besoins de Fonetix, une association de professeurs de FLE spécialisés dans la correction phonétique via la Méthode Verbo-Tonale. Le système aura deux fonctions principales :

1. Une segmentation syllabique précise et une transcription phonétique des productions des apprenants.
2. Un score de compréhensibilité offrant un retour pertinent aux apprenants.

1.1 Contexte du projet

Fonetix est une association qui offre aux professeurs et aux apprenants de Français Langue Étrangère (FLE) la possibilité de poursuivre l'apprentissage de la langue, et notamment de sa prononciation, à domicile. Pour ce faire, Fonetix propose via son application web (fonetix.org) une série d'exercices sélectionnés par les professeurs. Ces exercices s'appuient sur la **Méthode Verbo-Tonale** pour enseigner la prosodie — c'est-à-dire le rythme, l'accentuation et l'intonation de la langue. L'objectif principal est d'approfondir, voire de maîtriser, cette dimension de la langue afin d'améliorer la clarté de la prononciation et la compréhensibilité de la parole des apprenants, sans nécessairement insister sur la syntaxe ou la grammaire de leurs discours. Selon [19], l'importance de la prosodie dans l'enseignement et l'apprentissage d'une langue étrangère est un fait largement admis par les spécialistes du domaine. Pour les apprenants du français, une maîtrise approfondie de la prosodie est non seulement bénéfique, mais essentielle pour une communication efficace et naturelle. La prosodie, qui englobe le rythme, l'intonation et l'accentuation, joue en effet un rôle fondamental dans la compréhension et la production du sens.

1.2 Objectifs

En tant que prestataire auprès de l'association Fonetix, je souhaite donner une liste itérative des objectifs afin de proposer une tarification adaptée aux besoins, aux ambitions et aux ressources de Fonetix. La proposition suivante fonctionne en *gammes de tarification* mais également en étapes successives de recherche tel qu'il est nécessaire d'établir une *baseline* aux premières étapes de la recherche afin de pouvoir comparer les scores de performances et autres métriques obtenus aux étapes ultérieures du développement et ainsi proposer des algorithmes répondant aux exigences de Fonetix et à leurs besoins. La liste des objectifs est la suivante :

1. Concevoir et développer un phonémiseur Français et un algorithme de segmentation syllabique et ainsi établir une *baseline*. Proposer un score de compréhensibilité
2. Proposer un premier modèle d'analyse prosodique simple (e.g. durée, intensité des intonations, intonations montante, descendante ...)
3. Approfondir sur le modèle d'analyse prosodique, et proposer un algorithme complet de phonémisation, de segmentation syllabique et d'analyse prosodique du Français

Un objectif complémentaire est également d'optimiser le *tradeoff* entre la performance du modèle et son coût computationnel puisque cet algorithme doit être intégré au *backend* de l'application web fonetix.org.

2 Méthodologie de recherche

2.1 Objectif premier : conception d'une *baseline* de phonémisation, de segmentation syllabique et d'un score de compréhensibilité

Le premier objectif de cette recherche est d'établir une base de référence robuste pour la phonémisation, la segmentation syllabique et l'évaluation de la compréhensibilité de la parole en Français L2. Pour ce faire, je m'appuierai sur les travaux réalisés par Johann Audoye [2], en intégrant et en évaluant plusieurs outils et modèles qu'il a utilisés. Cette approche visera à jeter les fondations des étapes futures de la recherche.

Je reprendrai les outils et modèles suivants :

- le phonémiseur français [13]
- le modèle Whisper [16]
- le modèle Sylber [5]
- le logiciel PRAAT [8]
- le corpus annoté de Fonetix fourni avec les travaux de Johann Audoye

La mise en oeuvre rigoureuse des outils et des modèles mentionnés, et la génération de scores pour une *baseline* solide me permettra de valider les modèles et métriques pertinents et d'orienter la suite de mes recherches.

2.2 Deuxième objectif : proposer un modèle d'analyse prosodique

Au cours de mes recherches préliminaires, il a été établi que les modèles acoustiques récents, notamment ceux basés sur l'apprentissage auto-supervisé (*Self-Supervised Learning* - SSL) comme Wav2Vec 2.0 [3] et HuBERT [10], ainsi que des architectures génératives telles qu'AudioLM [4], sont intrinsèquement capables de représenter des informations prosodiques au sein de leurs embeddings latents.

L'objectif de cette section n'est donc pas de concevoir un nouveau modèle de représentation prosodique, mais plutôt d'exploiter l'information prosodique déjà encodée dans les couches de ces modèles existants via un modèle *downstream* dédié.

Je vais reprendre les modèles déjà existants et étudier leur capacité à retenir l'information prosodique :

1. **AudioLM** : Ce *framework* de génération audio opère en transformant l'audio en une séquence de tokens discrets, abordant la génération comme une tâche de modélisation linguistique dans cet espace de représentation. Il utilise une approche de tokenisation hybride, distinguant les tokens sémantiques – dérivés de modèles de langage masqués pré-entraînés sur l'audio (w2v-BERT [7]) – qui capturent la structure à long terme, y compris la syntaxe linguistique, le contenu sémantique et la prosodie du discours, et les tokens acoustiques – produits par un codec audio neuronal (SoundStream [20]) – qui permettent une synthèse de haute qualité et la capture des détails de la forme d'onde.

Les caractéristiques prosodiques sont majoritairement capturées par les tokens sémantiques, avec une contribution complémentaire des tokens acoustiques, permettant à AudioLM de générer des continuations de discours cohérentes tout en maintenant l'identité du locuteur et la prosodie des locuteurs non vus durant l'entraînement. [4]

2. **Wav2Vec 2.0** et **HuBERT** : Ces modèles SSL sont reconnus pour leur capacité à apprendre des représentations générales à partir de données audio non étiquetées.

- Wav2Vec 2.0 utilise une tâche contrastive pour distinguer les représentations latentes quantifiées et masquées de la forme d'onde brute, capturant des informations liées aux phonèmes. Il s'est avéré efficace pour l'identification du locuteur et la reconnaissance linguistique. [9]

HuBERT, de son côté, utilise un clustering hors ligne pour générer des étiquettes cibles alignées pour une tâche de prédiction de type BERT sur des régions masquées. Cela l'oblige à apprendre des représentations contextuelles et à saisir les relations temporelles à long terme. [10]

- Les modèles SSL démontrent une forte utilité pour les tâches liées à la prosodie. Ils montrent de bonnes performances dans la reconstruction de la prosodie (hauteur fondamentale (f0) et énergie) et la prédiction future de la prosodie [12] mais présentent toutefois des limitations. Ils peuvent parfois privilégier les variations locales ou sémantiques. [15] Il a été observé que le fine-tuning de Wav2Vec 2.0 pour la tâche de reconnaissance automatique de la parole (ASR) peut entraîner une perte d'informations utiles pour la reconnaissance des émotions, suggérant que les objectifs d'entraînement peuvent biaiser les représentations générées. [18] [14]

Ensuite, je devrai concevoir un modèle *downstream* pour extraire l'information prosodique pertinente des couches du modèle.

L'analogie avec l'exploitation des informations lexicales via des tâches d'ASR s'applique ici : il est essentiel de définir un modèle *downstream* et une tâche d'exploitation spécifique pour accéder et utiliser efficacement l'information prosodique déjà contenue dans ces représentations profondes. Ces représentations sont typiquement extraites des couches intermédiaires des modèles SSL et sont ensuite traitées par des modules plus légers adaptés aux tâches spécifiques – à définir.

Voici quelques exemples de modèles *downstream* et de leurs tâches spécifiques associées :

1. *Speech Emotion Recognition* (SER) : Les modèles adaptés fine-tunés basés sur Wav2Vec 2.0 et HuBERT atteignent des performances de pointe dans cette tâche, démontrant leur capacité à capturer des représentations prosodiques pertinentes pour l'émotion. [14] De plus, des travaux comme Prosody2Vec [15] ont montré que l'intégration d'un encodeur prosodique dédié, complémentaire aux représentations de HuBERT, peut même surpasser les méthodes de l'état de l'art pour le SER.
2. *Mispronunciation Detection and Diagnosis* (MDD) : Les modèles basés sur Wav2Vec 2.0, même après fine-tuning, peuvent être utilisés pour détecter les erreurs de prononciation. La performance de reconnaissance phonémique de ces modèles est corrélée avec la perception humaine de l'accentuation et de l'intelligibilité, bien que l'accentuation soit également influencée par des facteurs prosodiques dépassant les erreurs phonétiques segmentales. [11]
3. Organisation syllabique : SD-HuBERT [6], une version fine-tunée de HuBERT, est capable d'induire une organisation syllabique dans les représentations de la parole sans supervision externe. Des modèles ultérieurs comme Sylber [5] ont encore amélioré cette capacité, offrant des structures syllabiques claires et robustes ainsi qu'une tokenisation syllabique efficace. Ces unités syllabiques sont considérées comme des unités "phonologiquement ancrées" du discours.

En définitive, je vais devoir définir précisément une tâche *downstream* et concevoir l'architecture du modèle associé qui permettra d'extraire et de manipuler les informations prosodiques pertinentes déjà contenues dans ces représentations profondes.

2.3 Dernier objectif : approfondir le modèle prosodique et aborder une intégration holistique

En dernier objectif, je proposerais d'aller plus loin en créant un modèle prosodique plus sophistiqué en m'inspirant des travaux existants sur la représentation particulière de couches prosodiques et de hiérarchisation des tokens :

- **De l'apprentissage de représentations prosodiques décomposées** [15] : Le premier axe de cette modélisation avancée de la prosodie s'appuiera sur le modèle Prosody2Vec, un système auto-supervisé conçu pour apprendre des représentations prosodiques décomposées. Ce modèle a pour objectif de capturer les variations de style de parole et les états émotionnels sans nécessiter d'annotations humaines ou de transcriptions textuelles. L'architecture de Prosody2Vec intègre un encodeur d'unités pour séparer les informations paralinguistiques du contenu sémantique de la parole et – en parallèle – un encodeur prosodique entraînable apprend les informations prosodiques globaux ou au niveau de l'énoncé.

Les résultats expérimentaux ont démontré que Prosody2Vec capture efficacement des caractéristiques prosodiques générales transférables à d'autres discours émotionnels et qu'il est complémentaire aux modèles de représentation de la parole établis tels que Wav2Vec2 et HuBERT, permettant de surpasser l'état de l'art pour la reconnaissance d'émotions vocales (SER) lorsqu'il est combiné avec HuBERT.

Dans notre cas d'utilisation, je peux utiliser ce *framework* pour l'extraction et l'exploitation de caractéristiques plus fines – comme l'intonation montante ou descendante en fin de phrase –, ou pour une tâche d'évaluation de la prosodie de l'apprenant par rapport à une prosodie *target*.

- **De la hiérarchisation des tokens** [4] : Bien que ce modèle ait été initialement conçu pour la génération audio. AudioLM repose sur une approche hiérarchique qui combine deux types de tokens : les tokens sémantiques et les tokens acoustiques. [4] montrent que l'information prosodique est capturée principalement par les tokens sémantiques avec une participation moindre des tokens acoustiques. Cette architecture pourrait ainsi inspirer le développement d'un modèle d'analyse capable d'isoler et d'évaluer la cohérence prosodique des apprenants en se basant sur cette décomposition explicite des informations.

Quant au score de compréhensibilité, des métriques prosodiques – telles que le rythme [1], la réalisation des contours intonatifs [17] et la force perçue des frontières prosodiques [17] –, si extraites correctement, peuvent servir à pondérer le score et apporter une information englobante sur l'accentuation, le rythme et l'intonation du locuteur. En somme, un score de compréhensibilité pondéré offrirait un diagnostic plus complet pour les apprenants en Français L2.

Enfin, j'intégrerai le modèle de phonémisation et de segmentation syllabique avec le modèle prosodique et j'optimiserai le *tradeoff* performances / coût computationnel en vue d'une intégration de l'algorithme final dans l'application web fonetix.org.

3 Livrables attendus

Livrables par objectif

Objectif 1 :

- Algorithme phonémiseur livré en open-source [13]
- Algorithme de segmentation syllabique livré en open-source
- Algorithme de score de compréhensibilité livré en open-source
- Rapport de performance *baseline*

Objectif 2 :

- Algorithme d'analyse prosodique livré en open-source
- Rapport de comparaison des performances par rapport à la *baseline*

Objectif 3 :

- Algorithme intégré prêt pour intégration à l'application web
- Score de compréhensibilité amélioré
- Rapport de performance / *benchmarks* de performance

4 Planning et *milestones*

Il convient de préciser que ma disponibilité s'inscrit dans le cadre d'un **temps partiel**, correspondant à **deux journées de travail hebdomadaires** (soit 16 heures par semaine), ce qui représente une capacité de travail mensuelle de 8 journées (64 heures par mois).

- Option A - Objectif 1 uniquement :
Durée : 1 mois
Date de début : À définir après signature
Date de livraison : 1 mois après démarrage
- Option B - Objectifs 1 + 2 :
Durée : 1 + 8 mois = 9 mois
Date de début : À définir après signature
Date de livraison : 1 + 8 mois = 9 mois après démarrage
- Option C - Projet complet (Objectifs 1 + 2 + 3) :
Durée : 1 + 8 + 3 mois = 12 mois
Date de début : À définir après signature
Date de livraison : 1 + 8 + 3 mois = 12 mois après démarrage

5 Proposition tarifaire

Objectif	Nombre de jours	Taux journalier HT	Montant HT
Objectif 1 : <i>Baseline</i> phonémisation / segmentation	8 j (1 mois)	240,00 €	1 920,00 €
Objectif 2 : Modèle d'analyse prosodique	64 j (8 mois)	240,00 €	15 360,00 €
Objectif 3 : Intégration holistique et optimisation	24 j (3 mois)	240,00 €	5 760,00 €
Total	96 j		23 040,00 €

TABLE 1 – Décomposition tarifaire par objectif

Tarification modulaire

- Option A - Objectif 1 uniquement :
Montant HT : 1 920,00 €
TVA non applicable
Total TTC : 1 920,00 €

- Option B - Objectifs 1 + 2 :
Montant HT : 17 280,00 €
TVA non applicable
Total TTC : 17 280,00 €

- Option C - Projet complet (Objectifs 1 + 2 + 3) :
Montant HT : 23 040,00 €
TVA non applicable
Total TTC : 23 040,00 €

Termes et conditions

Ce devis concerne uniquement de la prestation de service.
TVA non applicable, article 293 B du Code Général des Impôts.

Bon pour accord.

Signé le :

À :

Références

- [1] Astésano, C. and Bertrand, R. (2016). Accentuation et niveaux de constituance en français : enjeux phonologiques et psycholinguistiques. *Langue française*, 191(3) :11–30.
- [2] Audoye, J. (2025). Fonetix : Remédiation phonétique et prononciation du français - usage des technologies du TAL pour la remédiation phonétique d'apprenants FLE : retour segmental et supra-segmental. Rapport de stage M2, Université Toulouse Jean Jaurès.
- [3] Baevski, A., Zhou, H., Mohamed, A., and Auli, M. (2020). wav2vec 2.0 : A framework for self-supervised learning of speech representations.
- [4] Borsos, Z., Marinier, R., Vincent, D., Kharitonov, E., Pietquin, O., Sharifi, M., Roblek, D., Teboul, O., Grangier, D., Tagliasacchi, M., and Zeghidour, N. (2023). Audioldm : a language modeling approach to audio generation.
- [5] Cho, C. J., Lee, N., Gupta, A., Agarwal, D., Chen, E., Black, A. W., and Anumanchipalli, G. K. (2025a). Sylber : Syllabic embedding representation of speech from raw audio.
- [6] Cho, C. J., Mohamed, A., Li, S.-W., Black, A. W., and Anumanchipalli, G. K. (2025b). Sd-hubert : Sentence-level self-distillation induces syllabic organization in hubert.
- [7] Chung, Y.-A., Zhang, Y., Han, W., Chiu, C.-C., Qin, J., Pang, R., and Wu, Y. (2021). W2v-bert : Combining contrastive learning and masked language modeling for self-supervised speech pre-training.
- [8] de Jong, N. H., Pacilly, J., and Heeren, W. (2021). Praat scripts to measure speed fluency and breakdown fluency in speech automatically. *Assessment in Education : Principles, Policy & Practice*, 28(4) :456–476.
- [9] Fan, Z., Li, M., Zhou, S., and Xu, B. (2021). Exploring wav2vec 2.0 on speaker verification and language identification.
- [10] Hsu, W.-N., Bolte, B., Tsai, Y.-H. H., Lakhotia, K., Salakhutdinov, R., and Mohamed, A. (2021). Hubert : Self-supervised speech representation learning by masked prediction of hidden units.
- [11] Kheir, Y. E., Ali, A., and Chowdhury, S. A. (2023). Automatic pronunciation assessment – a review.
- [12] Lin, G.-T., Feng, C.-L., Huang, W.-P., Tseng, Y., Lin, T.-H., Li, C.-A., yi Lee, H., and Ward, N. G. (2022). On the utility of self-supervised models for prosody-related tasks.
- [13] Olivier, M., Hauret, J., and Bavu, (2023). wav2vec2-french-phonemizer (revision e715906).
- [14] Pepino, L., Riera, P., and Ferrer, L. (2021). Emotion recognition from speech using wav2vec 2.0 embeddings.
- [15] Qu, L., Li, T., Weber, C., Pekarek-Rosin, T., Ren, F., and Wermter, S. (2023). Disentangling prosody representations with unsupervised speech reconstruction.
- [16] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., and Sutskever, I. (2022). Robust speech recognition via large-scale weak supervision.
- [17] Simon, A. C. and Christodoulides, G. (2016). Frontières prosodiques perçues : corrélats acoustiques et indices syntaxiques. *Langue française*, 191(3) :83–106.

- [18] Wang, Y., Boumadane, A., and Heba, A. (2022). A fine-tuned wav2vec 2.0/hubert benchmark for speech emotion recognition, speaker verification and spoken language understanding.
- [19] Witt, S. M. and Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech communication*, 30(2-3) :95–108.
- [20] Zeghidour, N., Luebs, A., Omran, A., Skoglund, J., and Tagliasacchi, M. (2021). Soundstream : An end-to-end neural audio codec.